

Informe exploratorio



INNOVAPAY

Tu dinero seguro y en movimiento

Informe de Análisis Exploratorio de Datos (EDA)

1. Estructura y Limpieza de los Datos

El conjunto de datos consta de 31,635 registros. Las variables clave analizadas son de naturaleza numérica y se enfocan en la actividad y satisfacción del cliente.

Análisis de la Variable Objetivo (churn_risk_score):

- Balance de Clases: El dataset está notablemente balanceado en relación con la variable objetivo binaria.
 - Clientes con Riesgo de Abandono Bajo (0/False): 15,868 (aprox. 50.16%).
 - Clientes con Riesgo de Abandono Alto (1/True): 15,767 (aprox. 49.84%).
- Hallazgos claves para Predicción: El equilibrio de la variable objetivo es óptimo para el entrenamiento de modelos de Machine Learning, ya que no se requerirán técnicas de sobremuestreo (oversampling) o submuestreo (undersampling) para corregir un desbalance.

2. Análisis Descriptivo de Variables Numéricas

Se realizó un análisis estadístico para 12 columnas numéricas, incluyendo edad, métricas de actividad y rendimiento transaccional.

Carácterística	Media	Mediana	Rango IQ	Valor Max
age	4.111	410	240	64
days_since_last_log	18.233	1.830	1.810	364
avg_time_spent	31.538	18.682	34.073	323.558
avg_transaction_val	2.930.444	2.760.253	2.660.936	9.991.405
nps_score	452	50	50	9
points_in_wallet	68.832	68.688	13.238	206.907
failed_tx	2.456	250	250	49

Hallazgos e Insights sobre Distribución:

- Métricas de Frecuencia y Uso:**
 - age y days_since_last_login:** Muestran una distribución relativamente normal con la media y mediana cercanas, y rangos de datos coherentes con los cuartiles. La mediana de edad es de 41 años.
 - failed_tx y tx_count_30d:** Tienen medias y medianas muy cercanas (24.56 vs 25 y 49.98 vs 50, respectivamente), indicando una distribución simétrica.
- Identificación de Clientes de Alto Valor/Actividad (Outliers):**
 - avg_time_spent (Tiempo Promedio Invertido):** Se observa una gran asimetría. La media (315.38) es significativamente más alta que la mediana (186.82). El valor máximo (3235.58) es un claro outlier, más de 7 veces el tercer cuartil (416.315).
Insight: Un pequeño grupo de clientes pasa una cantidad de tiempo desproporcionadamente alta en la plataforma. Este comportamiento extremo podría ser un fuerte predictor de lealtad o, por el contrario, de frustración si se acompaña de una alta failed_tx.

- **points_in_wallet (Puntos en Cartera):** Muestra un patrón similar al tiempo invertido. El valor máximo (2069.07) es mucho más alto que el tercer cuartil (757.07).
- **Satisfacción del Cliente (nps_score):** La mediana del NPS es 5, que típicamente se clasifica como una puntuación Pasiva (ni promotor ni detractor).

Insight: La plataforma tiene un margen significativo para mejorar la satisfacción del cliente y convertir a los usuarios pasivos en promotores, lo cual es crucial para la retención.

3. Análisis de Variables Categóricas y Gráficos

Se analizó la distribución de usuarios por grupos de edad y región.

- **Gráfico de Usuarios por Edad y Región:**

Análisis Gráfico (Usuarios por edad y región agrupados en segmentos de 10 años): Se observa que la distribución de usuarios varía considerablemente entre las diferentes region_category.

Observación: Al agrupar las edades en rangos, el gráfico permite identificar qué regiones tienen mayor concentración de clientes en grupos demográficos específicos (e.g., clientes jóvenes vs. mayores). Esto es un factor demográfico importante a considerar en el diseño de estrategias de retención segmentadas por región y edad.

- **Boxplots y Distribuciones**

El notebook incluye un conjunto de gráficos que comparan la distribución de las variables clave entre los dos grupos de riesgo de abandono (0: Bajo Riesgo y 1: Alto Riesgo).

Métrica	Insight Predictivo
avg_transaction_value	No predice la lealtad, sino que segmenta el valor del cliente. El abandono de un cliente con un avg_transaction_value alto es mucho más costoso.
points_in_wallet	La falta de uso de los puntos de lealtad, más que la cantidad, podría ser el predictor. Si tiene muchos puntos y se va, el modelo entiende que el programa de lealtad es irrelevante para ese segmento.
avg_frequency_login_days	Al combinarse con otras métricas, ayuda a distinguir entre un cliente inactivo (pero estable, con riesgo bajo) y un cliente que está activamente retirándose (frecuencia decreciente).